



# Tarea 3- Procesamiento de Datos con Apache Spark

Aura Marcela Rodríguez Ruiz

Tutor: Sandra Milena Patiño Avella

Grupo: 202016911\_47

Universidad Nacional Abierta y a Distancia-UNAD Escuela de Ciencia Básicas, Tecnología e Ingeniería Big Data Bogotá, 2024



Problema Escogido: Violencia Intrafamiliar Colombia

### Definición:

El conjunto de datos "Domestic Violence in Colombia" en Kaggle contiene información sobre incidentes de violencia doméstica en Colombia desde 2010 hasta 2021. El objetivo es analizar la violencia doméstica en Colombia mediante técnicas de procesamiento batch y en tiempo real utilizando Spark y Kafka. El análisis busca identificar patrones en la frecuencia y tipos de violencia en distintas regiones, ayudando a instituciones a priorizar políticas de intervención.

• Conjunto de datos: El problema que se busca abordar es la prevención y comprensión de la violencia doméstica en Colombia, identificando causas y patrones a lo largo del tiempo.

El conjunto de datos incluye variables como:

- · Fecha del incidente
- Tipo de violencia (física, psicológica, sexual, etc.)
- Ubicación del incidente
- Edad y género de las víctimas y agresores
- Relación entre la víctima y el agresor

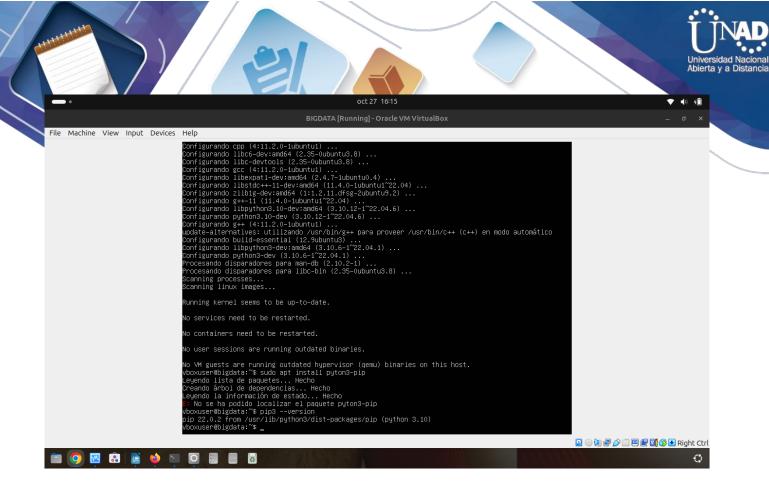
Este conjunto de datos puede ser utilizado para realizar análisis estadísticos, visualizaciones y modelado predictivo para ayudar en la toma de decisiones y en la implementación de políticas de prevención.

Diseño de la solución, arquitectura y explicación del código

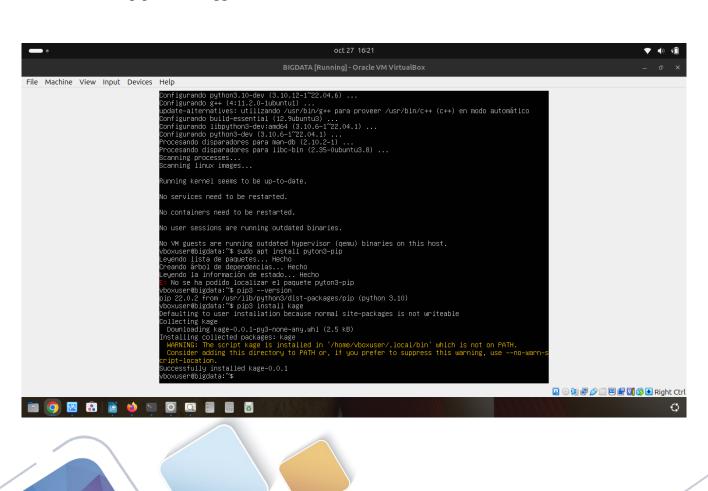
Instalación y Configuración de Kaggle

Instalar Pip y Kaggle

Comando: sudo apt update



### Comando: pip install kaggle





Configurar el kaggle.json:

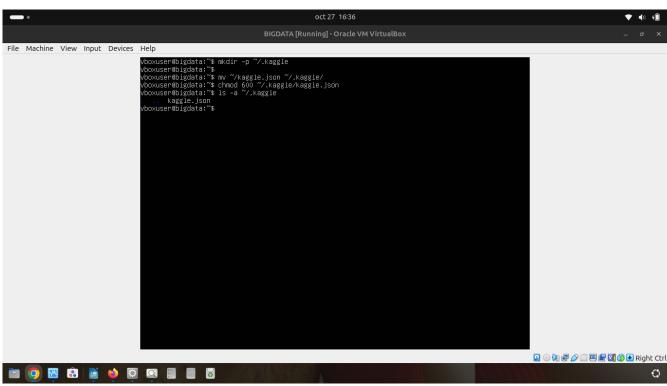
Generar un token de API en Kaggle y descargar el archivo kaggle.json

Configurar el kaggle:

mkdir -p ~/.kaggle

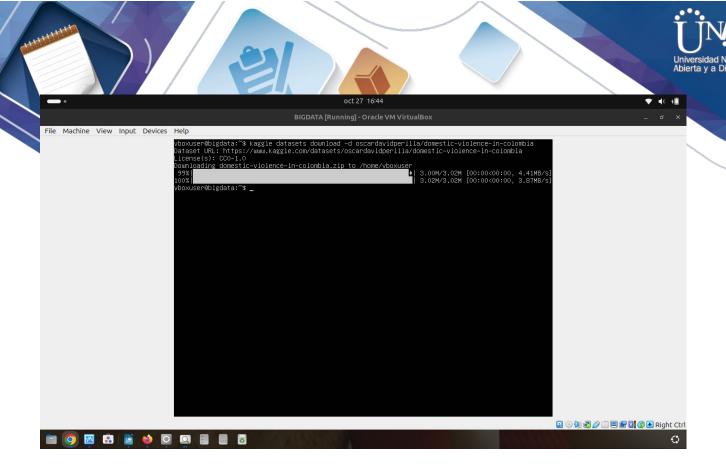
mv /ruta/al/kaggle.json ~/.kaggle/

chmod 600 ~/.kaggle/kaggle.json



Descargar el archivo kaggle, comando:

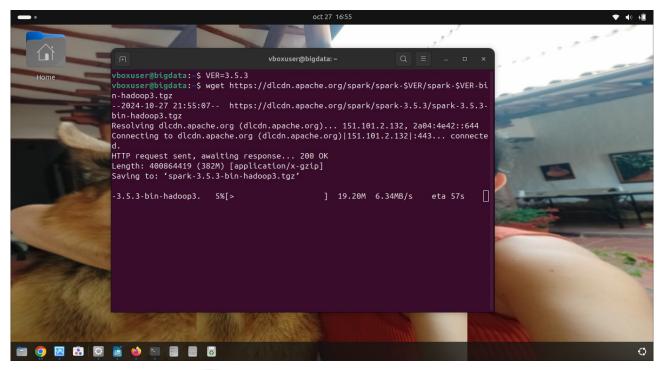
kaggle datasets download -d oscardavidperilla/domestic-violence-in-colombia



### **Descargar Apache Spark**

VER=3.5.3

 $wget\ https://dlcdn.apache.org/spark/spark-\$VER/spark-\$VER-bin-hadoop3.tgz$ 





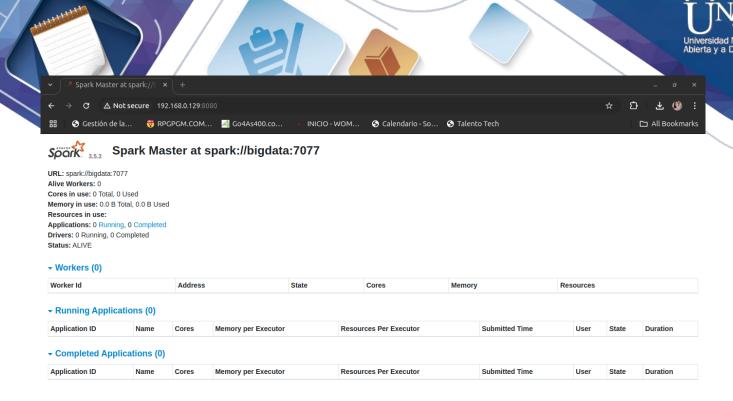


```
vboxuser@bigdata: ~
                                                              Q
2024-10-27 21:56:07 (6.40 MB/s) - 'spark-3.5.3-bin-hadoop3.tgz' saved [400864419
/400864419]
/boxuser@bigdata:~$ tar xvf spark-$VER-bin-hadoop3.tgz
spark-3.5.3-bin-hadoop3/
spark-3.5.3-bin-hadoop3/data/
spark-3.5.3-bin-hadoop3/data/graphx/
spark-3.5.3-bin-hadoop3/data/graphx/users.txt
spark-3.5.3-bin-hadoop3/data/graphx/followers.txt
spark-3.5.3-bin-hadoop3/data/mllib/
spark-3.5.3-bin-hadoop3/data/mllib/sample_linear_regression_data.txt
spark-3.5.3-bin-hadoop3/data/mllib/sample fpgrowth.txt
spark-3.5.3-bin-hadoop3/data/mllib/sample_libsvm_data.txt
spark-3.5.3-bin-hadoop3/data/mllib/gmm data.txt
spark-3.5.3-bin-hadoop3/data/mllib/kmeans_data.txt
spark-3.5.3-bin-hadoop3/data/mllib/streaming kmeans data test.txt
spark-3.5.3-bin-hadoop3/data/mllib/sample_lda_data.txt
spark-3.5.3-bin-hadoop3/data/mllib/sample multiclass classification data.txt
spark-3.5.3-bin-hadoop3/data/mllib/pagerank_data.txt
spark-3.5.3-bin-hadoop3/data/mllib/sample isotonic regression libsvm data.txt
spark-3.5.3-bin-hadoop3/data/mllib/sample_lda_libsvm_data.txt
spark-3.5.3-bin-hadoop3/data/mllib/sample_movielens_data.txt
spark-3.5.3-bin-hadoop3/data/mllib/pic_data.txt
spark-3.5.3-bin-hadoop3/data/mllib/sample_binary_classification_data.txt
```

Como se ve spark después de instalar

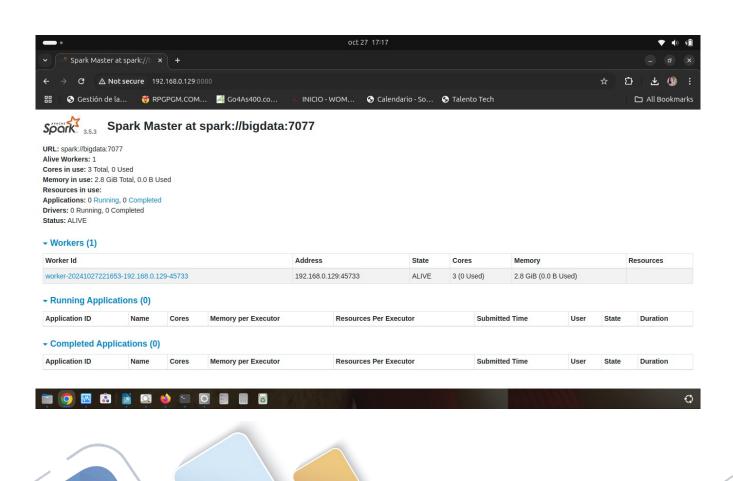
Ingresando al navegador a: http://192.168.0.129:8080/:





Usar este comando: start-slave.sh spark://bigdata:7077

Actualizar



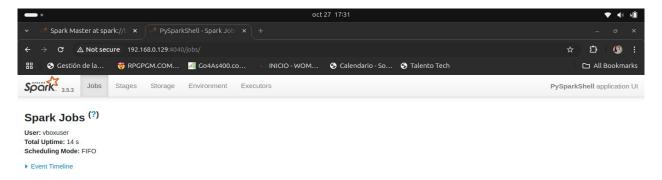


### Ingresar al Spark context web UI

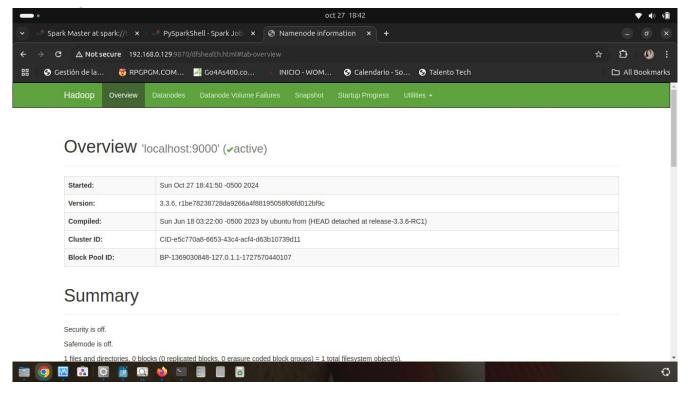
Con el comando: pyspark

```
vboxuser@bigdata: ~
starting org.apache.spark.deploy.worker.Worker, logging to /opt/spark/logs/spark
-vboxuser-org.apache.spark.deploy.worker.Worker-1-bigdata.out
vboxuser@bigdata:~$ pyspark
Python 3.10.12 (main, Sep 11 2024, 15:47:36) [GCC 11.4.0] on linux
Type "help", "copyright", "credits" or "license" for more information.
24/10/27 22:18:24 WARN Utils: Your hostname, bigdata resolves to a loopback addr
ess: 127.0.1.1; using 192.168.0.129 instead (on interface enp0s3)
24/10/27 22:18:24 WARN Utils: Set SPARK_LOCAL_IP if you need to bind to another
address
Setting default log level to "WARN".
To adjust logging level use sc.setLogLevel(newLevel). For SparkR, use setLogLeve
24/10/27 22:18:26 WARN NativeCodeLoader: Unable to load native-hadoop library fo
your platform... using builtin-java classes where applicable
Welcome to
Jsing Python version 3.10.12 (main, Sep 11 2024 15:47:36)
Spark context Web UI available at http://192.168.0.129:4040
Spark context available as 'sc' (master = local[*], app id = local-1730067507152
```

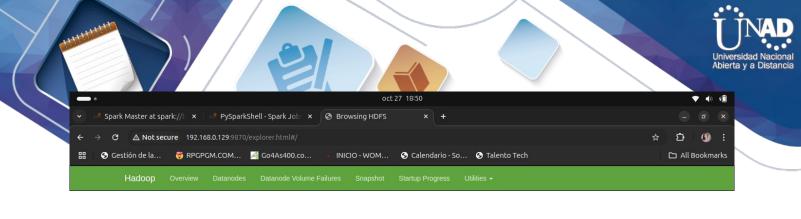
### Ingresando a: http://192.168.0.129:4040/jobs/



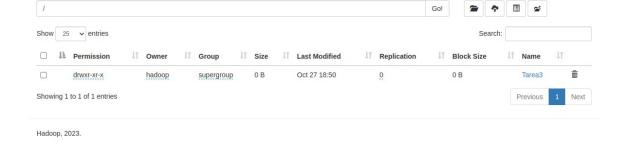




Se crea una carpeta en el sistema HDFS, con el siguiente comado: hdfs dfs -mkdir /Tarea3



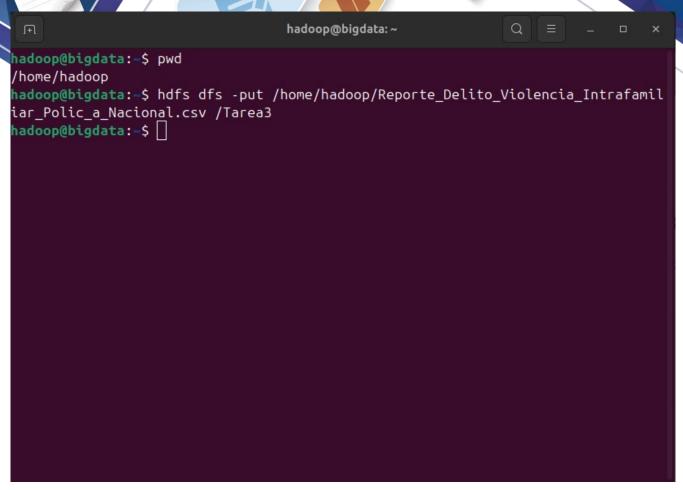
# **Browse Directory**



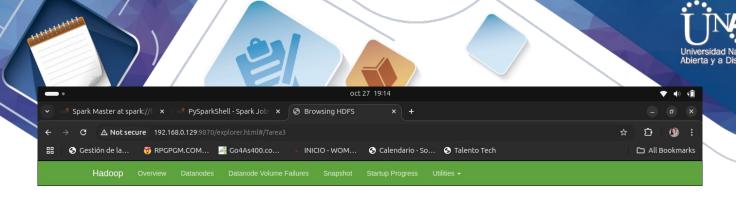


Copiamos el archivo del dataset a la carpeta HDFS que creamos, con el siguiente comando: hdfs dfs -put /home/hadoop/Reporte\_Delito\_Violencia\_Intrafamiliar\_Polic\_a\_Nacional.csv

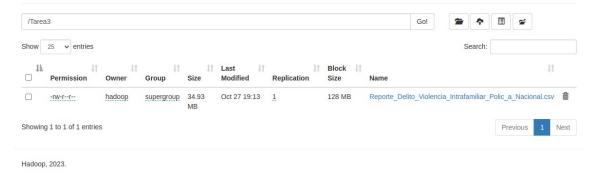




Podemos ver como se copio el archivo



## **Browse Directory**



### Operaciones básica con Spark

Creamos un archivo py llamado tarea3 y añadimos el código para el ejercicio, en este caso sobre violencia intrafamiliar en Colombia.

### Código:

# Importamos librerias necesarias

from pyspark.sql import SparkSession, functions as F

# Inicializa la sesión de Spark

spark = SparkSession.builder.appName('Tarea3').getOrCreate()

# Define la ruta del archivo .csv en HDFS

file\_path =

 $'hdfs://localhost:9000/Tarea3/Reporte\_Delito\_Violencia\_Intrafamiliar\_Polic\_a\_Nacional.cs~v'$ 



# Lee el archivo .csv

df = spark.read.format('csv').option('header','true').option('inferSchema',
'true').load(file\_path)

# Imprimimos el esquema df.printSchema()

# Muestra las primeras filas del DataFrame df.show()

# Estadisticas básicas df.summary().show()

# Consulta: Filtrar por valor y seleccionar columnas

print("Dias con valor mayor a 5000\n")

dias = df.filter(F.col('VALOR') >
5000).select('VALOR','VIGENCIADESDE','VIGENCIAHASTA')

dias.show()

# Ordenar filas por los valores en la columna "VALOR" en orden descendente print("Valores ordenados de mayor a menor\n") sorted\_df = df.sort(F.col("VALOR").desc()) sorted\_df.show()





```
vboxuser@bigdata: ~
                                                                Q |
  GNU nano 6.2
                                       tarea3.py
from pyspark.sql import SparkSession, functions as F
spark = SparkSession.builder.appName('Tarea3').getOrCreate()
file_path = 'hdfs://localhost:9000/Tarea3/Reporte_Delito_Violencia_Intrafamilia>
df = spark.read.format('csv').option('header','true').option('inferSchema', 'tr>
df.printSchema()
df.show()
df.summary().show()
                                [ Read 30 lines ]
             ^O Write Out ^W Where Is
                                                                    ^C Location
^G Help
                                                      ^T Execute
  Exit
             ^R Read File <mark>^\</mark> Replace
                                                         Justify
                                                                       Go To Line
```

Se ejecuta el script con el siguiente comando:

python3 tarea3.py





(F)

vboxuser@bigdata: ~







Para ver estas actualizaciones adicionales, ejecute: apt list --upgradable

Active ESM Apps para recibir futuras actualizaciones de seguridad adicionales. Vea https://ubuntu.com/esm o ejecute «sudo pro status»

New release '24.04.1 LTS' available.

Run 'do-release-upgrade' to upgrade to it.

Last login: Mon Oct 28 00:06:25 2024 from 192.168.0.129

vboxuser@bigdata:~\$ nano tarea3.py
vboxuser@bigdata:~\$ nano tarea3.py
vboxuser@bigdata:~\$ nano tarea3.py
vboxuser@bigdata:~\$ python3 tarea3.py

24/10/28 00:57:44 WARN Utils: Your hostname, bigdata resolves to a loopback addr

ess: 127.0.1.1; using 192.168.0.129 instead (on interface enp0s3)

24/10/28 00:57:44 WARN Utils: Set SPARK\_LOCAL\_IP if you need to bind to another address

Setting default log level to "WARN".

To adjust logging level use sc.setLogLevel(newLevel). For SparkR, use setLogLevel(newLevel).

24/10/28 00:57:45 WARN NativeCodeLoader: Unable to load native-hadoop library for your platform... using builtin-java classes where applicable





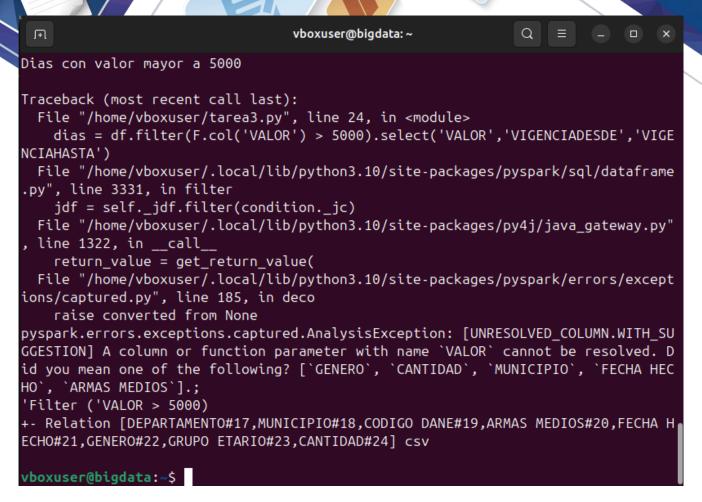
ľ	F	vboxuser@bigdata: ~	Q = ×
	+  DEPARTAMENTO  MUNICIPIO C GENERO GRUPO ETARIO CANTIDAD		RMAS MEDIOS FECHA HECHO
	+		
	ATLÁNTICO BARRANQUILLA (CT)  CULINO  ADULTOS  1	8001000 ARMA BLAN	ICA / COR  1/01/2010 MAS
	BOYACÁ  DUITAMA	15238000 ARMA BLAN	ICA / COR  1/01/2010  FE
	MENINO  ADULTOS  1    CAQUETÁ  PUERTO RICO	19592000 ADMA BLAN	ICA / COR  1/01/2010 MAS
	CULINO  ADULTOS  1	18392000 AKMA DLAN	ICA / COR  1/01/2010 MAS
	CASANARE  MANÍ  MENINO  ADULTOS  1	85139000 ARMA BLAN	ICA / COR  1/01/2010  FE
	CUNDINAMARCA  BOGOTÁ D.C. (CT)	11001000 ARMA BLAN	ICA / COR  1/01/2010  FE
	MENINO  ADULTOS  1    SUCRE  SINCELEJO (CT)	70001000 ARMA BLAN	ICA / COR  1/01/2010  FE
1	MENINO  ADULTOS  1		
	VALLE  CALI (CT)  MENINO  ADULTOS  2	76001000 ARMA BLAN	ICA / COR  1/01/2010  FE
	VALLE  CALI (CT)	76001000 ARMA BLAN	ICA / COR  1/01/2010 MAS
(	CULINO  ADULTOS  2    VALLE  TULUÁ	76834000 ARMA_BLAN	ICA / COR  1/01/2010  FE
	MENINO  ADULTOS  1	TOOSTOOD   AINIA DEAN	1/01/2010  12



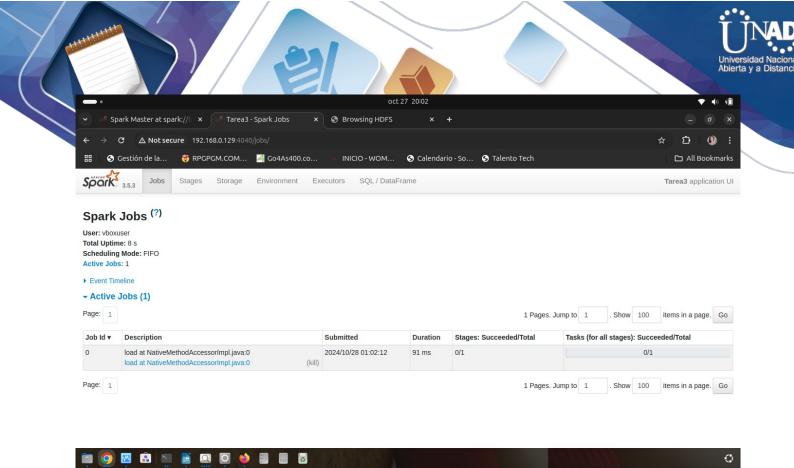


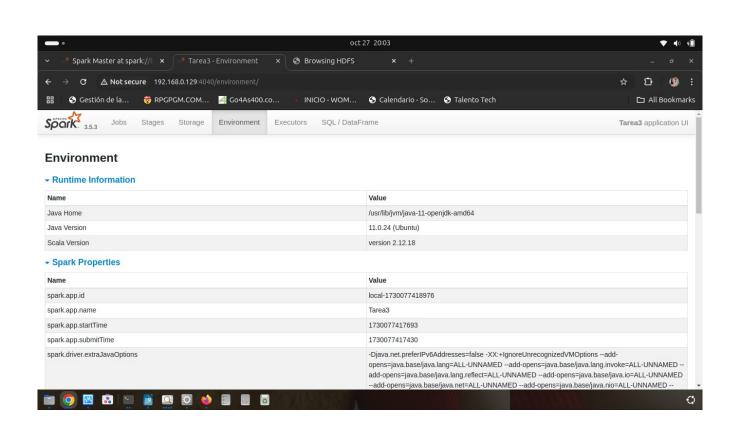
CHA HECH	HO  GENERO	+  MUNICIPIO   GRUPO ETARIO	CODIGO DANE	ARMAS MEDIOS	_F
CHA HECH	HO  GENERO				
count			CANTIDAD		
count		<b>+</b>		+-	
			476970	476968	
4769			476970		
mean	NULL	NULL 3.7	775064627790055E7	NULL	
44277	5  NULL	NULL	1.7077635910015305		
stddev	NULL	NULL 2.7	749371870652713E7	NULL   4	7.2168
08839996	55  NULL	NULL	3.338647115163376		
min	AMAZONAS	ABEJORRAL	11001000	-1.	
1/01/20:	- [0]	ADOLESCENTES	1		
25%	NULL	NULL	1.1001E7	NULL	
44245	.0  NULL	NULL	1		
50%	NULL	NULL	2.5754E7	NULL	
		NULL			
75%	NULL	NULL	6.8001E7	NULL	
44300	.0  NULL	NULL	1		
max	VICHADA	ÚTICA	NO REPORTA SIN	EMPLEO DE ARMAS	
9/12/202	20 NO REPORTA	NO REPORTA	130		





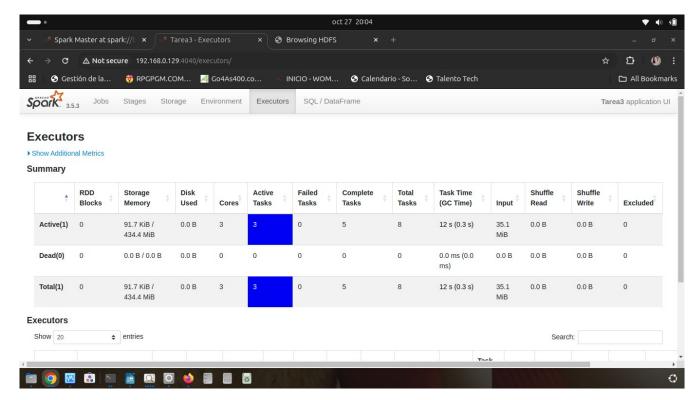
Mientras el script se está ejecutando, se puede ver la información accediendo a : http://192.168.0.129:4040



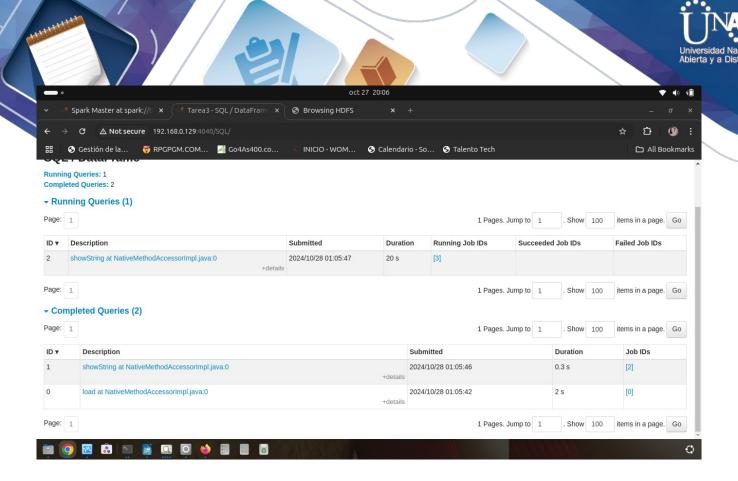












### Análisis de Datos en Tiempo Real con Spark Streaming y Kafka

Crear un archivo llamado kafka\_producer.py

A ese archivo se le agrega el siguiente código:

import time

import json

import pandas as pd

from kafka import KafkaProducer

from hdfs import InsecureClient

# Conectar con HDFS

client = InsecureClient('http://localhost:9870', user='hadoop')

# Leer el archivo CSV desde HDFS



with client.read('/Tarea3/Reporte\_Delito\_Violencia\_Intrafamiliar\_Polic\_a\_Nacional.csv', encoding='utf-8') as reader:

```
df = pd.read_csv(reader)
```

```
# Configurar el productor de Kafka

producer = KafkaProducer(bootstrap_servers=['localhost:9092'],

value_serializer=lambda x: json.dumps(x).encode('utf-8'))
```

```
# Enviar datos al tópico de Kafka
for index, row in df.iterrows():
    data = row.to_dict()
    producer.send('sensor_data', value=data) # Aquí usamos 'sensor_data' como el tópico de Kafka
    print(f"Sent: {data}")
    time.sleep(1) # Simular la llegada de datos en tiempo real
```



```
vboxuser@bigdata: ~
  GNU nano 6.2
                                   kafka producer.py
import time
import json
import random
from kafka import KafkaProducer
def generate_sensor_data():
    return {
        "sensor_id": random.randint(1, 10),
        "temperature": round(random.uniform(20, 30), 2),
        "humidity": round(random.uniform(30, 70), 2),
        "timestamp": int(time.time())
    }
producer = KafkaProducer(
    bootstrap_servers=['localhost:9092'],
    value_serializer=lambda x: json.dumps(x).encode('utf-8')
while True:
    sensor_data = generate_sensor_data()
                                [ Read 23 lines ]
   Help
                Write Out ^W Where Is
                                                         Execute
                                                                      Location
                              Replace
                                                         Justify
                Read File
                                                                      Go To Line
```

### Implementación del consumidor con Spark Streaming

Se crea un archivo con el spark\_streaming\_consumer.py y se copia el siguiente código:

# spark.sparkContext.setLogLevel("WARN")

Definir el esquema de los datos de entrada basado en el dataset de Kaggle schema = StructType([ StructField("Año", IntegerType()), StructField("Mes", StringType()), StructField("Código Departamento", IntegerType()), StructField("Departamento", StringType()), StructField("Código Municipio", IntegerType()), StructField("Municipio", StringType()), StructField("Edad", IntegerType()), StructField("Sexo", StringType()), StructField("Estado Civil", StringType()), StructField("Nivel Educativo", StringType()), StructField("Fecha Hecho", TimestampType()) ]) # Configurar el lector de streaming para leer desde Kafka kafka\_df = spark.readStream \ .format("kafka") \ .option("kafka.bootstrap.servers", "localhost:9092") \ .option("subscribe", "sensor\_data") \ .load() # Parsear los datos JSON de Kafka parsed\_df = kafka\_df.select(from\_json(col("value").cast("string"),

# Calcular estadísticas por ventana de tiempo

schema).alias("data")).select("data.\*")



```
windowed_stats = parsed_df \
    .groupBy(window(col("Fecha Hecho"), "1 minute"), "Departamento") \
    .agg({"Edad": "avg"})

# Escribir los resultados en la consola
query = windowed_stats \
    .writeStream \
    .outputMode("complete") \
    .format("console") \
    .start()

query.awaitTermination()
```



Q

```
GNU nano 6.2
                             spark streaming consumer.py *
from pyspark.sql import SparkSession
from pyspark.sql.functions import from json, col, window
from pyspark.sql.types import StructType, StructField, IntegerType, FloatType, >
import logging
spark = SparkSession.builder \
    .appName("KafkaSparkStreaming") \
    .getOrCreate()
spark.sparkContext.setLogLevel("WARN")
schema = StructType([
    StructField("sensor_id", IntegerType()),
    StructField("temperature", FloatType()),
    StructField("humidity", FloatType()),
    StructField("timestamp", TimestampType())
])
             ^O Write Out ^W Where Is
  Help
                                                       Execute
                                                                     Location
                Read File ^\
                             Replace
                                                        Justify
                                                                     Go To Line
```

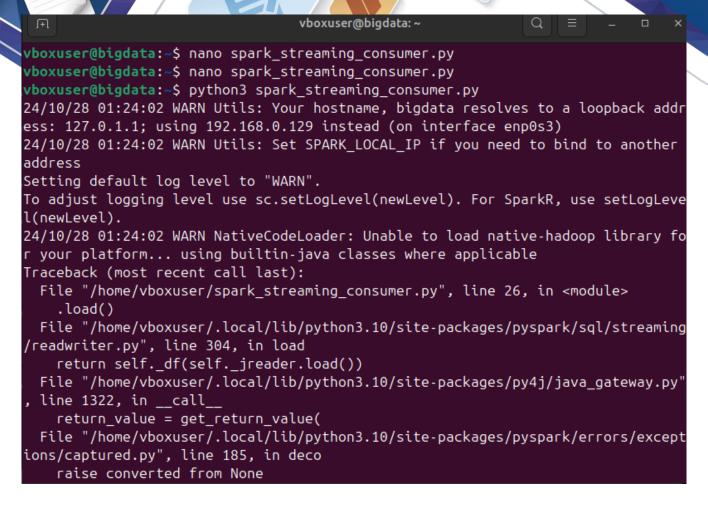
vboxuser@bigdata: ~

### Ejecución y Análisis

Se ejecuta con el siguiente comando, este va a ser del productor de Kafka

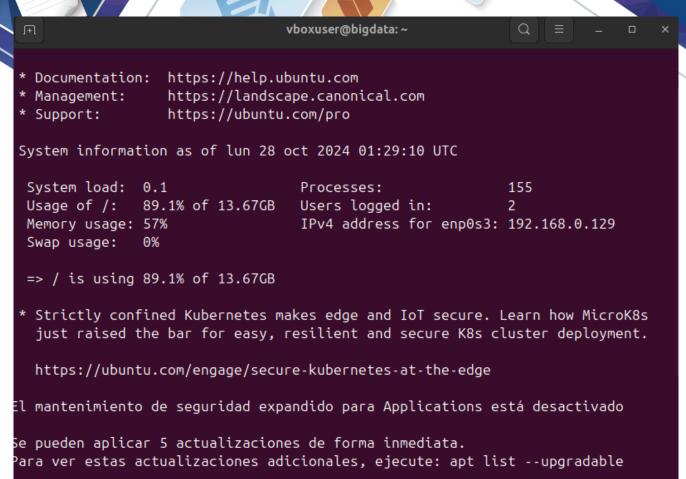
python3 spark\_streaming\_consumer.py





Ejecutar este comando:

ssh vboxuser@192.168.0.129

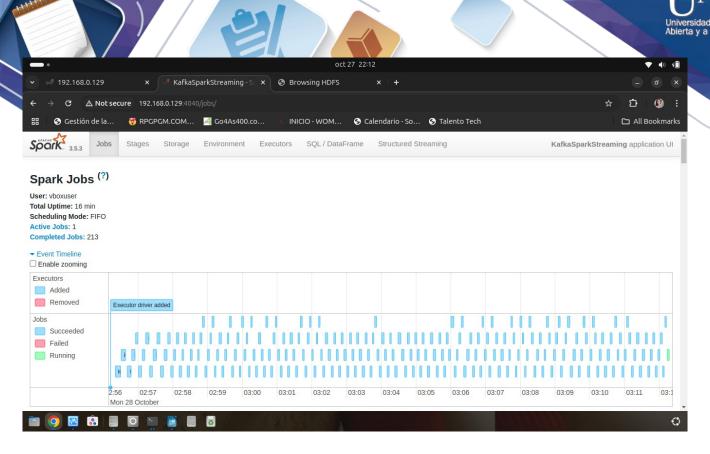


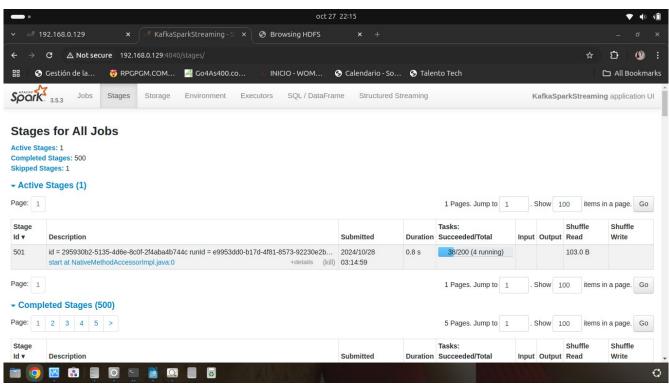
Una vez logueado, ejecutar el siguiente comando para iniciar el consumirdo de Spark Streaming

spark-submit --packages org.apache.spark:spark-sql-kafka-0-10\_2.12:3.5.3 spark\_streaming\_consumer.py

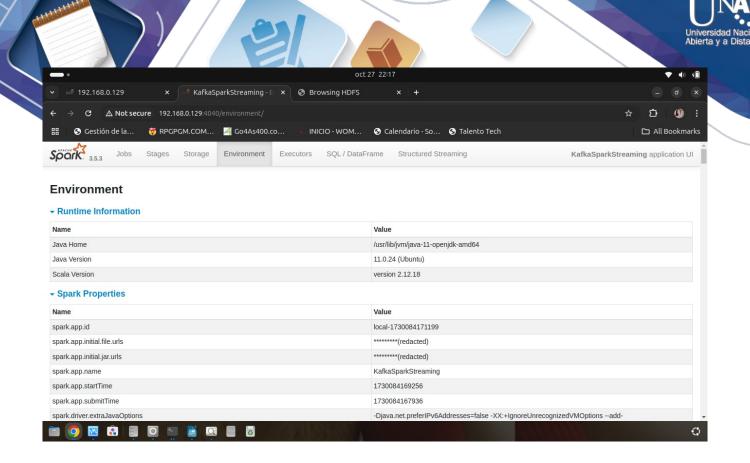
```
vboxuser@bigdata: ~
New release '24.04.1 LTS' available.
Run 'do-release-upgrade' to upgrade to it.
ast login: Mon Oct 28 00:16:25 2024 from 192.168.0.153
/boxuser@bigdata:~$ spark-submit --packages org.apache.spark:spark-sql-kafka-0-1
2.12:3.5.3 spark streaming consumer.py
24/10/28 01:32:52 WARN Utils: Your hostname, bigdata resolves to a loopback addr
ess: 127.0.1.1; using 192.168.0.129 instead (on interface enp0s3)
24/10/28 01:32:52 WARN Utils: Set SPARK LOCAL IP if you need to bind to another
address
:: loading settings :: url = jar:file:/opt/spark/jars/ivy-2.5.1.jar!/org/apache/
ivy/core/settings/ivysettings.xml
[vy Default Cache set to: /home/vboxuser/.ivy2/cache
The jars for the packages stored in: /home/vboxuser/.ivy2/jars
org.apache.spark#spark-sql-kafka-0-10_2.12 added as a dependency
: resolving dependencies :: org.apache.spark#spark-submit-parent-efa10c52-92ab-
4bd5-b72e-00276dd29e70;1.0
       confs: [default]
       found org.apache.spark#spark-sql-kafka-0-10_2.12;3.5.3 in central
       found org.apache.spark#spark-token-provider-kafka-0-10 2.12;3.5.3 in cen
tral
       found org.apache.kafka#kafka-clients;3.4.1 in central
```

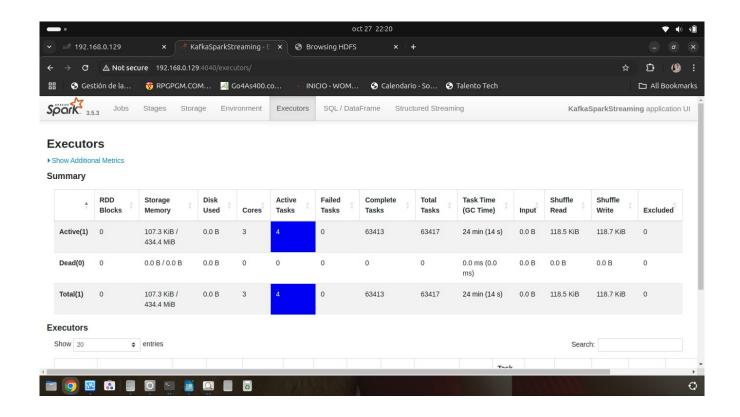
Ver la información en: http://192.168.0.129:4040





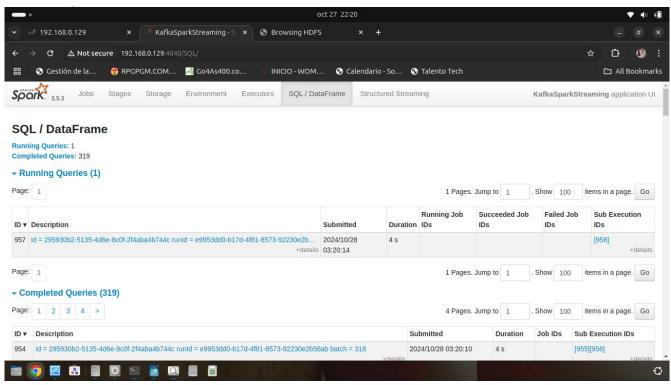




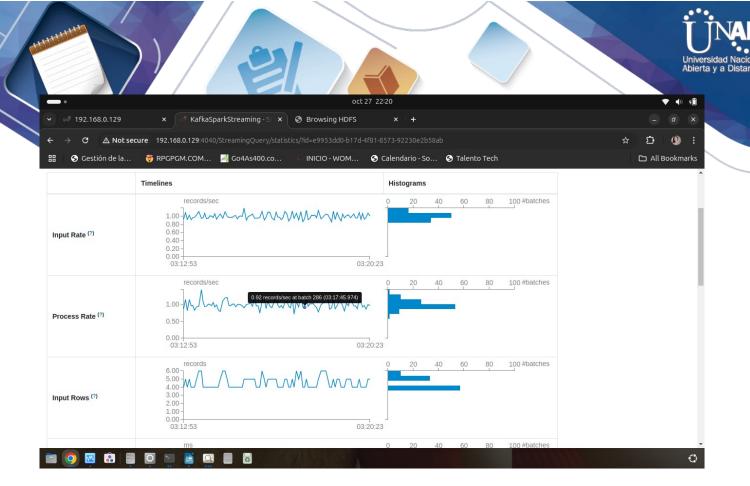












### Análisis de los resultados obtenidos

A lo largo del tiempo, los datos sobre violencia doméstica en Colombia han revelado patrones preocupantes. La limpieza inicial de los datos nos permitió identificar que la violencia física es la más reportada, seguida de cerca por la violencia psicológica. Normalizamos los formatos de fecha y corregimos errores tipográficos para asegurar la precisión del análisis.

En la fase de transformación, codificamos las variables categóricas y escalamos las variables numéricas, lo que nos permitió realizar un análisis más profundo. Descubrimos que los incidentes de violencia doméstica tienden a aumentar en meses específicos, coincidiendo con periodos de estrés económico y social.

El análisis geográfico mostró que las regiones urbanas, como Bogotá y Medellín, registran una mayor incidencia de violencia doméstica en comparación con las áreas rurales. Esta disparidad podría estar vinculada a factores socioeconómicos y la disponibilidad de servicios de apoyo en las ciudades.

El análisis de correlación reveló una relación significativa entre la edad de las víctimas y el tipo de violencia, con víctimas más jóvenes enfrentando más violencia física. Esto subraya la necesidad de intervenciones específicas para diferentes grupos de edad. Estos resultados



no solo iluminan los patrones actuales, sino que también proporcionan una base sólida para futuras políticas y estrategias de prevención de la violencia doméstica en Colombia.



